

Studiengang: Angewandte Künstliche Intelligenz
Modul: DLBAIPNLP01_D - Projekt: NLP
Tutorin: Maja Popovic
Semester: 4

Projekt:
**Automatische Auswertung maschineller
Übersetzungen mit n-Gramm-Metriken**

Datum: 14.05.2026
Name: Götz Möglinger
Adresse: Werneckstr. 35
80802 München
E-Mail: goetz.moeglinger@iu-study.org
Matrikelnummer: IU14106219

Inhalt

1	Einleitung	1
1.1	Zielsetzung	1
1.2	Forschungsfragen.....	2
1.3	Geplantes Vorgehen und Aufbau des Berichts.....	2
2	Methodik und technische Umsetzung.....	3
2.1	Datensatz und methodische Grundlage	3
2.2	Verwendete Bewertungsmetriken	3
2.2.1	BLEU	4
2.2.2	chrF	4
2.2.3	chrF++	5
2.2.4	Beispiel zur Funktionsweise der Bewertungsmetriken	5
2.3	Berechnung und Evaluationsverfahren	6
2.4	Technische Umsetzung.....	6
3	Evaluation und Metriken	7
3.1	Zwischenergebnisse der ersten Bewertung	7
3.2	Bewertung mit der besten maschinellen Übersetzung als Referenz	8
3.3	Vergleich und Diskussion der Rangfolgen.....	10
3.4	Limitationen und Ausblick	10
4	Fazit.....	11
5	Abschlussreflexion	11
	Literaturverzeichnis.....	13

1 Einleitung

Die automatische Übersetzung natürlicher Sprache zählt zu den wichtigsten Anwendungsfeldern des Natural Language Processing (NLP). Moderne Systeme der maschinellen Übersetzung ermöglichen inzwischen qualitativ hochwertige Übersetzungen zwischen vielen verschiedenen Sprachen und werden in zahlreichen Anwendungsbereichen eingesetzt.

Die Bewertung solcher Übersetzungen stellt jedoch weiterhin eine zentrale Herausforderung dar. Im Gegensatz zu klassischen Klassifikationsaufgaben existiert bei Übersetzungen häufig nicht nur eine einzige korrekte Lösung. Unterschiedliche Formulierungen können dieselbe Bedeutung korrekt wiedergeben, obwohl sie sprachlich und strukturell unterschiedlich sind (Jurafsky & Martin, 2025). Dadurch wird die automatische Bewertung maschineller Übersetzungen erschwert, da reine Wortübereinstimmungen die tatsächliche Qualität einer Übersetzung oft nur eingeschränkt erfassen können.

Zur automatischen Bewertung maschineller Übersetzungen werden daher verschiedene n-Gramm-basierte Bewertungsmetriken eingesetzt. Besonders verbreitet sind dabei Metriken wie BLEU oder chrF. Während BLEU hauptsächlich auf Wort-n-Grammen basiert (Papineni et al., 2002, S. 311), verwendet chrF zeichenbasierte n-Gramme, die sprachunabhängig eingesetzt werden können und morphologische Variationen besser erfassen (Popović, 2015, S. 392).

Vor diesem Hintergrund untersucht die vorliegende Projektarbeit das Verhalten unterschiedlicher n-Gramm-Metriken bei der Bewertung maschineller Übersetzungen im Sprachpaar Englisch–Deutsch. Dabei werden insbesondere Unterschiede in den Bewertungen sowie die resultierenden Rangfolgen verschiedener Übersetzungssysteme analysiert.

1.1 Zielsetzung

Ziel dieser Projektarbeit ist die Untersuchung und der Vergleich verschiedener n-Gramm-basierter Bewertungsmetriken zur automatischen Bewertung maschineller Übersetzungen. Im Mittelpunkt stehen dabei die Metriken BLEU, chrF und chrF++, die anhand maschinell erzeugter Übersetzungen im Sprachpaar Englisch–Deutsch untersucht werden.

Die Arbeit soll zeigen, wie unterschiedlich automatische Bewertungsmetriken maschinelle Übersetzungen bewerten und welche Auswirkungen dies auf die Rangfolgen verschiedener Übersetzungssysteme hat. Dabei wird insbesondere der Unterschied zwischen wortbasierten und zeichenbasierten Bewertungsverfahren betrachtet.

Zusätzlich wird untersucht, wie stark die Wahl der Referenzübersetzung die Bewertungsergebnisse beeinflusst. Dazu werden die Übersetzungssysteme zunächst mit einer menschlichen Referenzübersetzung bewertet. Anschließend wird die leistungsstärkste maschinelle Übersetzung als neue Referenz verwendet, um die Stabilität der Bewertungsmetriken gegenüber Veränderungen der Referenz zu analysieren.

Darüber hinaus soll untersucht werden, inwiefern sich die Erweiterung von chrF zu chrF++ auf das Bewertungsverhalten auswirkt und ob sich dadurch Unterschiede gegenüber rein wortbasierten oder rein zeichenbasierten Verfahren zeigen.

Im Mittelpunkt der Arbeit steht dabei nicht die Entwicklung eigener Übersetzungsmodelle, sondern die praktische Untersuchung automatischer Evaluationsverfahren für maschinelle Übersetzungen.

1.2 Forschungsfragen

Die automatische Bewertung maschineller Übersetzungen stellt eine besondere Herausforderung dar, da unterschiedliche Übersetzungen dieselbe Bedeutung korrekt wiedergeben können, obwohl sie sprachlich unterschiedlich formuliert sind. Dadurch stellt sich die Frage, wie zuverlässig automatische Bewertungsmetriken die Qualität solcher Übersetzungen erfassen können.

Vor diesem Hintergrund untersucht die vorliegende Arbeit, wie sich die n-Gramm-Metriken BLEU, chrF und chrF++ bei der Bewertung maschineller Übersetzungen im Sprachpaar Englisch–Deutsch unterscheiden. Dabei steht insbesondere im Mittelpunkt, welche Auswirkungen die Wahl der jeweiligen Bewertungsmetrik auf die berechneten Qualitätswerte sowie auf die daraus entstehenden Rangfolgen der Übersetzungssysteme hat.

Zusätzlich wird untersucht, wie sich unterschiedliche Referenzübersetzungen auf die Bewertungsergebnisse auswirken. Dabei soll analysiert werden, wie stabil die einzelnen Bewertungsmetriken gegenüber Veränderungen der Referenzübersetzung reagieren.

1.3 Geplantes Vorgehen und Aufbau des Berichts

Zur Untersuchung der Forschungsfragen wird zunächst ein Datensatz mit maschinellen Übersetzungen im Sprachpaar Englisch–Deutsch ausgewählt. Der Datensatz enthält neben den Ausgangstexten mehrere maschinell erzeugte Übersetzungen verschiedener Systeme sowie menschliche Referenzübersetzungen.

Im nächsten Schritt werden die n-Gramm-basierten Bewertungsmetriken BLEU, chrF und chrF++ eingesetzt, um die Ähnlichkeit zwischen den maschinellen Übersetzungen und einer Referenzübersetzung zu berechnen. Die daraus entstehenden Bewertungswerte werden verwendet, um Rangfolgen der Übersetzungssysteme zu erstellen und miteinander zu vergleichen.

Anschließend wird die leistungstärkste maschinelle Übersetzung als neue Referenz verwendet, um die übrigen Übersetzungssysteme erneut zu bewerten. Dadurch soll untersucht werden, wie stark die Bewertungsmetriken von der gewählten Referenzübersetzung abhängen.

Die Arbeit gliedert sich dazu in die Bereiche Datensatz und Methodik, technische Umsetzung, Evaluation der Bewertungsmetriken sowie Analyse und Diskussion der Ergebnisse.

2 Methodik und technische Umsetzung

2.1 Datensatz und methodische Grundlage

Für die Untersuchung der verschiedenen Bewertungsmetriken wird ein Datensatz aus dem WMT24-News-Systems-Datensatz verwendet. Die WMT-Shared-Tasks zählen zu den wichtigsten Benchmarks im Bereich der maschinellen Übersetzung und werden häufig zur Evaluation moderner Übersetzungssysteme eingesetzt.

Der verwendete Datensatz enthält maschinelle Übersetzungen verschiedener Übersetzungssysteme sowie menschliche Referenzübersetzungen für mehrere Sprachpaare. In dieser Arbeit wird das Sprachpaar Englisch–Deutsch untersucht.

Die Übersetzungen liegen zeilenweise vor, wobei jede Zeile einer einzelnen Übersetzungseinheit beziehungsweise einem Satz entspricht. Dadurch können die einzelnen Übersetzungen direkt miteinander verglichen werden.

Da der verwendete Datensatz dem News-Bereich zugeordnet ist, wurde keine weitere Aufteilung nach unterschiedlichen Domänen vorgenommen.

Eigenschaft	Wert
Datensatz	WMT24 News Systems
Sprachpaar	Englisch–Deutsch
Domäne	News / Nachrichten
Anzahl Übersetzungszeilen	998
Anzahl Wörter im Quelltext	32.348
Anzahl maschineller Übersetzungssysteme	26
Anzahl menschlicher Referenzübersetzungen	2
Verwendete Hauptreferenz	refA

2.2 Verwendete Bewertungsmetriken

Zur automatischen Bewertung maschineller Übersetzungen existieren verschiedene Bewertungsmetriken, die die Ähnlichkeit zwischen maschinell erzeugten Übersetzungen und menschlichen Referenzübersetzungen berechnen. Je nach Aufbau der jeweiligen Metrik werden

dabei unterschiedliche sprachliche Eigenschaften berücksichtigt. Während einige Verfahren hauptsächlich auf Wortebene arbeiten, verwenden andere zusätzlich zeichenbasierte Informationen.

In dieser Arbeit werden die n-Gramm-basierten Bewertungsmetriken BLEU, chrF und chrF++ untersucht. Ziel ist es, Unterschiede im Bewertungsverhalten dieser Metriken sowie deren Auswirkungen auf die Bewertung und Rangfolge verschiedener Übersetzungssysteme zu analysieren.

2.2.1 BLEU

BLEU (Bilingual Evaluation Understudy) zählt zu den bekanntesten automatischen Bewertungsmetriken für maschinelle Übersetzungen und wird seit vielen Jahren häufig in der Forschung eingesetzt (Papineni et al., 2002, S. 311).

Die Metrik basiert auf der Idee, maschinell erzeugte Übersetzungen mit einer menschlichen Referenzübersetzung zu vergleichen und daraus einen Ähnlichkeitswert zu berechnen. Dabei untersucht BLEU hauptsächlich die Übereinstimmung von Wortfolgen, sogenannten Wort-n-Grammen. Ein 1-Gramm entspricht dabei einem einzelnen Wort, ein 2-Gramm einer Folge aus zwei aufeinanderfolgenden Wörtern und so weiter.

BLEU berücksichtigt mehrere Wort-n-Gramm-Längen gleichzeitig und bewertet dadurch nicht nur einzelne Wörter, sondern auch Wortreihenfolgen und Teile der Satzstruktur. Je mehr Wortfolgen zwischen maschineller Übersetzung und Referenzübersetzung übereinstimmen, desto höher fällt der BLEU-Wert aus.

Ein Vorteil von BLEU liegt in der vergleichsweise einfachen und schnellen Berechnung sowie in der guten Vergleichbarkeit verschiedener Übersetzungssysteme. Gleichzeitig besitzt die Metrik auch Einschränkungen. Da BLEU hauptsächlich auf direkten Wortübereinstimmungen basiert, können sprachlich korrekte Umformulierungen oder Synonyme zu niedrigeren Bewertungen führen, obwohl die Bedeutung der Übersetzung erhalten bleibt.

2.2.2 chrF

Neben BLEU wird in dieser Arbeit die Bewertungsmetrik chrF verwendet. Die Abkürzung chrF steht für *character n-gram F-score* und wurde von Popović (2015, S. 392) zur automatischen Bewertung maschineller Übersetzungen vorgeschlagen.

Im Gegensatz zu BLEU basiert chrF nicht hauptsächlich auf Wortfolgen, sondern auf Zeichen-n-Grammen (Popović, 2015, S. 392). Dabei werden die Übersetzungen in kleinere Zeichenfolgen zerlegt und anschließend mit der Referenzübersetzung verglichen. Durch die Verwendung von Zeichenfolgen kann chrF auch Ähnlichkeiten zwischen Wörtern erkennen, die sich nur teilweise unterscheiden.

Dadurch reagiert die Metrik häufig robuster auf Flexionen, kleinere sprachliche Abweichungen oder alternative Formulierungen als rein wortbasierte Verfahren wie BLEU. Die Bewertung erfolgt über

einen sogenannten F-Score, der die Übereinstimmung zwischen maschineller Übersetzung und Referenzübersetzung zusammenfasst.

Da chrF auf Zeichenebene arbeitet, eignet sich die Metrik besonders für Übersetzungen mit sprachlichen Variationen oder kleineren Wortveränderungen. In der Forschung zur maschinellen Übersetzung wird chrF deshalb häufig als Ergänzung oder Alternative zu BLEU verwendet. In verschiedenen Untersuchungen zeigte chrF zudem eine gute Übereinstimmung mit menschlichen Bewertungen maschineller Übersetzungen (Popović, 2015, S. 395).

2.2.3 chrF++

Neben chrF wird zusätzlich die erweiterte Variante chrF++ betrachtet. Während chrF ausschließlich auf Zeichen-n-Grammen basiert, kombiniert chrF++ zeichenbasierte und wortbasierte Informationen miteinander (Popović, 2017, S. 612).

Dadurch berücksichtigt chrF++ neben Zeichenähnlichkeiten zusätzlich auch Teile der Wortstruktur einer Übersetzung. Ziel dieser Erweiterung ist es, sowohl kleinere sprachliche Unterschiede als auch größere Wortübereinstimmungen in die Bewertung einzubeziehen.

Ähnlich wie chrF reagiert auch chrF++ häufig robuster auf sprachliche Variationen als rein wortbasierte Verfahren wie BLEU. Da chrF++ sowohl zeichenbasierte als auch wortbasierte Informationen kombiniert, stellt die Metrik einen interessanten Vergleich zwischen den unterschiedlichen Bewertungsansätzen dar.

2.2.4 Beispiel zur Funktionsweise der Bewertungsmetriken

Referenzübersetzung: Das Wetter ist heute schön.

Maschinenübersetzung: Das Wetter ist heute angenehm.

Metrik	Grundlage der Bewertung	Beispielhafte Übereinstimmungen	Wirkung
BLEU	Wort-n-Gramme	„Das Wetter“, „Wetter ist“, „ist heute“	Reagiert stärker auf andere Wörter oder Umformulierungen
chrF	Zeichen-n-Gramme	Zeichenfolgen wie: „Wett“, „etter“, „heu“, „te“, „ist“	Erkennt auch teilweise ähnliche Wörter und kleinere sprachliche Unterschiede
chrF++	Zeichen-n-Gramme + Wort-n-Gramme	kombiniert Zeichenfolgen und zusätzliche Wortinformationen	Berücksichtigt sowohl Zeichenähnlichkeiten als auch Wortstruktur

Das Beispiel verdeutlicht, dass unterschiedliche Bewertungsmetriken verschiedene sprachliche Eigenschaften einer Übersetzung berücksichtigen. Während BLEU hauptsächlich direkte Wortübereinstimmungen bewertet, analysiert chrF Zeichenfolgen innerhalb der Wörter. chrF++ erweitert diesen Ansatz zusätzlich um wortbasierte Informationen.

2.3 Berechnung und Evaluationsverfahren

Zur Bewertung der maschinellen Übersetzungen werden die Metriken BLEU, chrF und chrF++ auf alle ausgewählten Übersetzungssysteme angewendet. Dabei wird zunächst die menschliche Referenzübersetzung „refA“ als Hauptreferenz verwendet.

Für jedes Übersetzungssystem werden die Metrikwerte zunächst zeilenweise für jede einzelne Übersetzungseinheit berechnet. Anschließend wird aus den einzelnen Satzbewertungen jeweils ein Durchschnittswert für das gesamte Übersetzungssystem bestimmt. Auf Grundlage dieser Durchschnittswerte werden die verschiedenen Übersetzungssysteme anschließend in Rangfolgen eingeordnet und miteinander verglichen.

Zusätzlich werden die Bewertungsmetriken auch auf Korpusebene berechnet, da BLEU ursprünglich als corpus-level Metrik entwickelt wurde (Papineni et al., 2002, S. 311). Dabei werden nicht einzelne Sätze, sondern der gesamte Übersetzungskorpus als zusammenhängender Text bewertet. Die Korpusbewertung dient in dieser Arbeit hauptsächlich als ergänzender Vergleich zur satzweisen Berechnung.

Da die Aufgabenstellung Durchschnittswerte über einzelne Übersetzungszeilen vorsieht, liegt der Schwerpunkt der weiteren Analyse auf den sentence-level Durchschnittswerten.

Anschließend wird jeweils die Übersetzung mit dem höchsten Metrikwert als neue Referenz verwendet. Mit dieser neuen Referenz werden alle übrigen Übersetzungssysteme sowie die ursprüngliche menschliche Referenzübersetzung erneut bewertet und wieder in Rangfolgen eingeordnet.

2.4 Technische Umsetzung

Die technische Umsetzung der Arbeit erfolgt in Python innerhalb einer Jupyter-Notebook-Umgebung. Für die Verarbeitung der Übersetzungsdateien sowie die Berechnung der Bewertungsmetriken werden verschiedene Python-Bibliotheken verwendet.

Die Übersetzungen und Referenzdateien werden zunächst zeilenweise eingelesen und strukturiert verarbeitet. Da alle Übersetzungssysteme dieselbe Anzahl an Übersetzungszeilen besitzen, können die einzelnen Sätze direkt miteinander verglichen werden.

Zur Berechnung der Bewertungsmetriken BLEU, chrF und chrF++ wird die Bibliothek *SacreBLEU* verwendet. Die Bibliothek enthält standardisierte Implementierungen verschiedener Bewertungsmetriken für maschinelle Übersetzungen und wird häufig in der Forschung eingesetzt (Post, 2018, S. 186).

Der entwickelte Python-Code unterstützt unterschiedliche Texteinheiten und n-Gramm-Längen. Während BLEU hauptsächlich wortbasierte n-Gramme verwendet, arbeiten chrF und chrF++ zusätzlich mit zeichenbasierten n-Grammen. Die notwendige Tokenisierung der Texte wird dabei automatisch durch die verwendete Bibliothek durchgeführt.

Die berechneten Bewertungswerte werden anschließend tabellarisch gespeichert und für die Erstellung der Rangfolgen weiterverarbeitet. Zusätzlich werden ausgewählte Ergebnisse grafisch dargestellt, um Unterschiede zwischen den einzelnen Bewertungsmetriken besser vergleichen zu können.

3 Evaluation und Metriken

3.1 Zwischenergebnisse der ersten Bewertung

Im ersten Schritt der Evaluation wurden alle ausgewählten Übersetzungssysteme mithilfe der Bewertungsmetriken BLEU, chrF und chrF++ mit der menschlichen Referenzübersetzung „refA“ verglichen. Die Berechnung erfolgte zunächst zeilenweise für jede einzelne Übersetzungseinheit. Anschließend wurde aus den einzelnen Satzbewertungen jeweils ein Durchschnittswert für das gesamte Übersetzungssystem bestimmt.

Zusätzlich wurden die Bewertungsmetriken ergänzend auch auf Korpusebene berechnet. Dabei zeigte sich, dass sich die Werte der satzweisen Durchschnittsberechnung und der Korpusbewertung zwar unterscheiden, insgesamt jedoch ähnliche Tendenzen in den Rangfolgen der Übersetzungssysteme erkennbar sind. Im weiteren Verlauf der Arbeit liegt der Schwerpunkt daher auf den sentence-level Durchschnittswerten.

Bei der ersten Auswertung zeigte sich außerdem, dass chrF und chrF++ insgesamt ein sehr ähnliches Bewertungsverhalten aufweisen. Obwohl chrF++ zusätzlich wortbasierte Informationen berücksichtigt, unterscheiden sich die resultierenden Rangfolgen nur geringfügig. Um die weitere Analyse übersichtlicher zu gestalten, konzentriert sich die Arbeit im Folgenden hauptsächlich auf den Vergleich zwischen BLEU und chrF.

Die Ergebnisse der durchschnittlichen Satzbewertungen zeigen, dass unterschiedliche Bewertungsmetriken teilweise zu unterschiedlichen Rangfolgen der Übersetzungssysteme führen. Beim durchschnittlichen sentence-level BLEU erreichte das System *TranssionMT* mit einem Wert von 33,86 den höchsten Wert. Beim durchschnittlichen sentence-level chrF erzielte dagegen „Claude-3.5“ mit einem Wert von 60,35 den höchsten Wert.

Damit zeigen die ersten Ergebnisse bereits, dass unterschiedliche Bewertungsmetriken nicht zwangsläufig dieselben Übersetzungssysteme bevorzugen. Während BLEU stärker auf direkte Wortübereinstimmungen reagiert, berücksichtigt chrF aufgrund der zeichenbasierten Vorgehensweise auch kleinere sprachliche Abweichungen und alternative Formulierungen stärker.

System	BLEU corpus	BLEU sentence_avg	chrF corpus	chrF sentence_avg	chrF++ corpus	chrF++ sentence_avg
TranssionMT	34,66	33,86	61,68	59,97	59,14	57,59
ONLINE-B	34,63	33,81	61,65	59,93	59,1	57,54
ONLINE-W	33,43	32,79	61,55	59,67	59,01	57,37
GPT-4	33,15	33,18	61,33	60,05	58,74	57,65
Claude-3.5	33,12	33,45	61,46	60,35	58,85	57,98
ONLINE-A	32,58	32,88	60,93	59,57	58,32	57,2
IOL-Research	32,52	31,96	59,93	58,34	57,48	56,01
Gemini-1.5-Pro	32,42	32,45	60,63	58,84	58,14	56,64
ONLINE-G	31,81	31,24	59,92	57,64	57,27	55,19
Mistral-Large	31,5	32,41	60,41	59,52	57,88	57,07
Dubformer	31,22	32,53	59,49	59,74	56,8	57,3
Unbabel-Tower70B	30,98	31,63	59,26	58,67	56,57	56,21
CommandR-plus	30,98	32,13	59,96	59,3	57,33	56,92
Aya23	30,5	30,68	58,83	57,42	56,23	55,03
Llama3-70B	29,58	28,65	58,48	55,64	55,78	53,12
IKUN	28,79	28,57	56,95	55,33	54,27	52,87
IKUN-C	27,11	27,86	55,65	54,34	52,97	51,98
Phi-3-Medium	26,87	26,57	56,66	54,13	53,87	51,57
NVIDIA-NeMo	26,66	23,98	55,68	51,2	52,94	48,64
AIST-AIRC	25,53	26,24	54,49	52,8	51,77	50,33
CUNI-NL	24,58	26,41	52,73	52,72	50,17	50,34
Occiglot	22,46	18,9	49,31	43,01	46,62	40,64
MSLC	20,11	20,13	49,82	46,33	46,88	43,75
TSU-HITs	12,17	16,63	35,44	40,8	33,21	38,48
CycleL2	8	8,74	35,72	32,49	32,78	29,78
CycleL	8	8,74	35,72	32,49	32,78	29,78
Maxwert	34,66	33,86	61,68	60,35	59,14	57,98

Da die Aufgabenstellung zusätzlich die Verwendung der besten maschinellen Übersetzung als neue Referenz vorsieht, wird im nächsten Schritt das System *TranssionMT* als neue Referenzübersetzung verwendet, da es insgesamt am besten abgeschnitten hat. Anschließend werden alle übrigen Übersetzungssysteme sowie die ursprüngliche menschliche Referenzübersetzung erneut mithilfe von BLEU und chrF bewertet.

3.2 Bewertung mit der besten maschinellen Übersetzung als Referenz

Im nächsten Schritt der Evaluation wurde untersucht, wie sich die Bewertung der Übersetzungssysteme verändert, wenn nicht mehr die menschliche Referenzübersetzung *refA*, sondern die beste maschinelle Übersetzung als neue Referenz verwendet wird. Grundlage hierfür war die erste Auswertung der sentence-level Durchschnittswerte. Da das System *TranssionMT* beim durchschnittlichen BLEU-Wert den höchsten Wert erreichte und gleichzeitig auch bei chrF zu den leistungsstärksten Systemen gehörte, wurde es als neue Referenzübersetzung ausgewählt.

Anschließend wurden alle übrigen Übersetzungssysteme sowie die ursprüngliche menschliche Referenzübersetzung erneut mithilfe von BLEU und chrF mit der Übersetzung von *TranssionMT* verglichen. Ziel dieses Schrittes war es zu untersuchen, wie stark die Bewertungsmetriken von der jeweils gewählten Referenzübersetzung abhängen.

Die Ergebnisse zeigen deutlich, dass sich die Rangfolgen und Bewertungswerte teilweise erheblich verändern können, sobald eine andere Referenzübersetzung verwendet wird. Besonders auffällig ist dabei, dass einige maschinelle Übersetzungssysteme sehr hohe Ähnlichkeitswerte zu *TranssionMT* erreichen. So erzielt beispielsweise *ONLINE-B* einen durchschnittlichen BLEU-Wert von 98,89 sowie einen chrF-Wert von 99,38 im Vergleich zur neuen Referenz. Dies deutet darauf hin, dass beide Systeme sprachlich und strukturell sehr ähnliche Übersetzungen erzeugen.

Gleichzeitig zeigt sich jedoch ein besonders interessanter Effekt bei der ursprünglichen menschlichen Referenzübersetzung. Obwohl diese sprachlich korrekt und qualitativ hochwertig ist, erreicht sie im Vergleich zu *TranssionMT* lediglich einen durchschnittlichen BLEU-Wert von 33,85 sowie einen chrF-Wert von 59,74. Die menschliche Übersetzung wird somit deutlich niedriger bewertet als mehrere maschinelle Übersetzungssysteme.

Dieses Ergebnis verdeutlicht eine zentrale Einschränkung automatischer Bewertungsmetriken wie BLEU und chrF. Die Metriken bewerten in erster Linie die sprachliche Ähnlichkeit zur gewählten Referenzübersetzung und nicht direkt die tatsächliche semantische Qualität einer Übersetzung. Unterschiedliche Formulierungen mit gleicher Bedeutung können dadurch deutlich schlechter bewertet werden, obwohl sie inhaltlich korrekt sind. Besonders BLEU reagiert empfindlich auf Veränderungen in Wortwahl und Satzstruktur, da die Metrik hauptsächlich direkte Wortübereinstimmungen und Wortfolgen bewertet. chrF zeigt aufgrund der zeichenbasierten Vorgehensweise insgesamt etwas stabilere Bewertungen, bleibt jedoch ebenfalls deutlich von der gewählten Referenzübersetzung abhängig.

Die zweite Bewertung mit *TranssionMT* als Referenz verdeutlicht somit, dass automatische Bewertungsmetriken stark von der verwendeten Referenzübersetzung abhängen. Je ähnlicher ein Übersetzungssystem zur Referenz formuliert, desto höher fällt in der Regel auch die Bewertung aus.

System	BLEU avg_vs_ TranssionMT	chrF avg_vs_ TranssionMT
TranssionMT	100	100
ONLINE-B	98,89	99,38
ONLINE-A	55,02	74,74
ONLINE-W	53,48	74,26
ONLINE-G	52,79	73,67
Claude-3.5	52,56	73,67
GPT-4	51,43	73,99
Gemini-1.5-Pro	50,78	71,06
IOL-Research	49,41	70,74
Mistral-Large	48,99	71,13
Dubformer	48,43	70,87
CommandR-plus	47,88	70,42
Unbabel-Tower70B	47,84	69,91
Aya23	46,01	69,02
Llama3-70B	44,72	68,81
IKUN	41,48	65
Phi-3-Medium	39,04	64,83
IKUN-C	38,5	61,82
NVIDIA-NeMo	36,13	62,13
AIST-AIRC	36,05	59,96
CUNI-NL	35,03	59,58
Human_refA	33,85	59,74
Occiglot	27,13	49,53
MSLC	25,88	51,01
TSU-HITs	21,45	45,24
CycleL2	11,19	35,58
CycleL	11,19	35,58
Maxwert	98,89	99,38

3.3 Vergleich und Diskussion der Rangfolgen

Der Vergleich der unterschiedlichen Rangfolgen zeigt, dass automatische Bewertungsmetriken teilweise deutlich auf Veränderungen der Referenzübersetzung reagieren. Obwohl viele der leistungsstärksten Systeme sowohl bei der ersten als auch bei der zweiten Bewertung im oberen Bereich der Rangfolgen bleiben, verändern sich einzelne Positionen sichtbar.

Besonders deutlich wird dabei, dass Übersetzungssysteme, die sprachlich ähnlich zur gewählten Referenz formulieren, höhere Bewertungen erhalten als Systeme mit stärker abweichenden Formulierungen. Dies zeigt sich insbesondere bei der zweiten Bewertung mit *TranssionMT* als Referenz, bei der einige maschinelle Systeme sehr hohe Ähnlichkeitswerte erreichen, während die ursprüngliche menschliche Referenzübersetzung deutlich niedriger bewertet wird.

Die Ergebnisse verdeutlichen damit, dass automatische Bewertungsmetriken wie BLEU und chrF in erster Linie Oberflächenähnlichkeiten zwischen Übersetzungen erfassen. Besonders BLEU reagiert empfindlich auf Veränderungen in Wortwahl und Satzstruktur, da direkte Wortübereinstimmungen und Wortfolgen bewertet werden. chrF zeigt aufgrund der zeichenbasierten Vorgehensweise insgesamt etwas stabilere Bewertungen, bleibt jedoch ebenfalls von der gewählten Referenzübersetzung abhängig.

Darüber hinaus zeigen die Ergebnisse, dass moderne maschinelle Übersetzungssysteme teilweise sehr ähnliche Formulierungen erzeugen. Besonders leistungsstarke Systeme weisen häufig hohe gegenseitige Ähnlichkeiten auf, was vermutlich auf ähnliche Trainingsdaten und Modellarchitekturen zurückzuführen ist.

Insgesamt verdeutlichen die Ergebnisse, dass automatische Bewertungsmetriken zwar eine gute Vergleichbarkeit unterschiedlicher Übersetzungssysteme ermöglichen, die tatsächliche sprachliche Qualität einer Übersetzung jedoch nur eingeschränkt erfassen können.

3.4 Limitationen und Ausblick

Die vorliegende Arbeit konzentriert sich auf die automatische Bewertung maschineller Übersetzungen mithilfe n-Gramm-basierter Bewertungsmetriken. Dabei wurden ausschließlich die Metriken BLEU, chrF und chrF++ untersucht. Moderne semantische Bewertungsverfahren, die zusätzlich Bedeutungsinformationen oder große Sprachmodelle einbeziehen, wurden im Rahmen dieser Arbeit nicht betrachtet.

Eine weitere Einschränkung besteht darin, dass lediglich ein einzelnes Sprachpaar sowie ein ausgewählter Datensatz untersucht wurden. Die Ergebnisse lassen sich daher nicht ohne Weiteres auf andere Sprachpaare oder Anwendungsbereiche übertragen.

Die Ergebnisse der Arbeit zeigen außerdem, dass automatische Bewertungsmetriken stark von der gewählten Referenzübersetzung abhängen. Unterschiedliche Formulierungen können trotz gleicher

Bedeutung zu deutlich abweichenden Bewertungen führen. Dies stellt eine grundlegende Herausforderung automatischer Evaluationsverfahren dar.

Für zukünftige Arbeiten wäre insbesondere ein Vergleich mit semantischen Bewertungsverfahren wie BERTScore oder COMET interessant, da diese semantische Ähnlichkeiten mithilfe kontextueller Sprachrepräsentationen berücksichtigen und eine höhere Korrelation mit menschlichen Bewertungen erreichen können (Zhang et al., 2019, S. 1; Rei et al., 2020, S. 2685).

4 Fazit

Ziel dieser Projektarbeit war die Untersuchung verschiedener n-Gramm-basierter Bewertungsmetriken zur automatischen Bewertung maschineller Übersetzungen. Dazu wurden die Metriken BLEU, chrF und chrF++ anhand maschineller Übersetzungssysteme im Sprachpaar Englisch–Deutsch untersucht und miteinander verglichen.

Die Ergebnisse zeigen, dass unterschiedliche Bewertungsmetriken teilweise zu unterschiedlichen Rangfolgen der Übersetzungssysteme führen. Besonders deutlich wurde dabei der Einfluss der verwendeten Referenzübersetzung. Sobald statt der menschlichen Referenz eine maschinelle Übersetzung als neue Referenz verwendet wurde, veränderten sich die Bewertungen und Rangfolgen teilweise deutlich.

Die Arbeit verdeutlicht außerdem, dass automatische Bewertungsmetriken hauptsächlich sprachliche Ähnlichkeiten zur Referenzübersetzung erfassen. Inhaltlich korrekte Übersetzungen können dadurch niedriger bewertet werden, wenn sie sprachlich anders formuliert sind. Dies zeigte sich insbesondere daran, dass die ursprüngliche menschliche Referenzübersetzung im Vergleich zur maschinellen Referenz teilweise schlechter bewertet wurde als andere maschinelle Systeme.

Insgesamt zeigen die Ergebnisse, dass automatische Bewertungsmetriken eine wichtige Grundlage für den Vergleich maschineller Übersetzungen darstellen, die tatsächliche sprachliche Qualität jedoch nur eingeschränkt erfassen können.

5 Abschlussreflexion

Im Rahmen der Projektarbeit konnte ein vertieftes Verständnis für die automatische Bewertung maschineller Übersetzungen sowie für die Funktionsweise verschiedener n-Gramm-basierter Bewertungsmetriken gewonnen werden. Besonders interessant war dabei die praktische Untersuchung der Unterschiede zwischen wortbasierten und zeichenbasierten Bewertungsverfahren.

Durch die eigenständige Implementierung der Bewertungsverfahren in Python wurde deutlich, wie stark sich bereits kleine Veränderungen in der Referenzübersetzung auf die resultierenden Bewertungen auswirken können. Die Arbeit zeigte außerdem, dass automatische Bewertungsmetriken nicht direkt die tatsächliche Bedeutung einer Übersetzung erfassen, sondern hauptsächlich sprachliche Ähnlichkeiten zur Referenzübersetzung bewerten.

Besonders hilfreich war die praktische Arbeit mit realen Übersetzungsdaten aus dem WMT24-Datensatz. Dadurch konnten die theoretischen Konzepte der automatischen Übersetzungsbewertung direkt anhand realer Übersetzungssysteme nachvollzogen werden.

Rückblickend wurde außerdem deutlich, dass die Interpretation automatischer Bewertungsmetriken komplexer ist als zunächst erwartet. Obwohl die berechneten Werte auf den ersten Blick eindeutig erscheinen, hängt ihre Aussagekraft stark von der gewählten Bewertungsmethode sowie von der verwendeten Referenzübersetzung ab.

Alle Unterlagen zu diesem Bericht finden sie auch in meinem GitHub Rep unter dem Link:

<https://github.com/goetzmoeglinger/IU-Projekt-NLP>

Literaturverzeichnis

- Jurafsky, D. & Martin, J. H. (20. August 2024). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*. <https://web.stanford.edu/~jurafsky/slp3>
- Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). *BLEU: a Method for Automatic Evaluation of Machine Translation*. Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL), 311–318. <https://aclanthology.org/P02-1040.pdf>
- Popović, M. (2015). *chrF: character n-gram F-score for automatic MT evaluation*. Proceedings of the Tenth Workshop on Statistical Machine Translation, 392–395. <https://aclanthology.org/W15-3049.pdf>
- Popović, M. (2017). *chrF++: words helping character n-grams*. Proceedings of the Second Conference on Machine Translation, 612–618. <https://aclanthology.org/W17-4770.pdf>
- Post, M. (2018). *A Call for Clarity in Reporting BLEU Scores*. Proceedings of the Third Conference on Machine Translation, 186–191. <https://aclanthology.org/W18-6319.pdf>
- Rei, R., Stewart, C., Farinha, A. C., & Lavie, A. (2020). *COMET: A neural framework for MT evaluation*. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (pp. 2685–2702). Association for Computational Linguistics. <https://aclanthology.org/2020.emnlp-main.213/>
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2019). *BERTScore: Evaluating text generation with BERT*. arXiv. <https://arxiv.org/abs/1904.09675>